

1

Курс простой. По нему зачёт.

Нужно решить 4 лабораторные работы:

- Регулярные выражения в языке **Perl**. Самостоятельное изучение материала и сдача в PCMS. Если сдавать в 2022, то можно решить N-3 задач. До конца сессии -2. После -1 (все, кроме одной).
- До 22:00 в пн нужно будет записываться на сдачу лабораторных 2,3,4. Показываешь, что работает. Получаешь модификацию (их много разных на одно и то же задание). Потом показываешь уже модификацию.
- ЛР2 – ручное построение нисходящих парсеров
- ЛР3 – использование автоматических генераторов парсеров. ANTLR, Happy, Bison (YACC)
- ЛР4 – написать автоматический генератор парсеров

Компиляция: программа → парсинг → генерация исполнимого кода.

Здесь пройдем первый основы парсинга (довольно глубоко), а генерацию кода только базовую основу.

Если вы пойдёте в магистратуру, там будет курс компиляторов. Там фокус наоборот на генерации.

В курсе нет дедлайнов. НО удачи вам с тайм-менеджментом без них :v) Курс по софт-скиллам, you're welcom

Что такое пасрер?

текстовое представление информации → внутреннее представление компьютера. Чаще всего дерево разбора в некоторой контекстно-свободной грамматике.


Регулярное выражение – способ записать регулярные языки.

Контекстно свободная грамматика – алфавит, множество нетерминалов, стартовый нетерминал и правила.

неоднозначная:

$$S \rightarrow (S)$$
$$S \rightarrow SS$$
$$S \rightarrow e$$

однозначная:

$$S \rightarrow (S)S$$
$$S \rightarrow e$$


Токенизация: инпут в *любом* формате $\rightarrow c_1, c_2, \dots, c_n$, где c_i это токены.

Синтаксический/Лексический анализ (парсинг)

Лексический анализатор:

Есть входной алфавит парсера. Есть совсем входной алфавит A (ASCII условно).

Пример: арифметические выражения $\Sigma = \{+, -, *, (,), number\}$.

Числа здесь не нужны. $2+3$, $5+5$, $17+231$. Всё это считается одним выражением. Поэтому есть один токен для числа.

+

— —

* *

))

((

$$n \quad (1|2|3|4|5|6|7|8|9)(0|1|2|\dots|9)^*|0$$

```
17+231
```

```
n
```

```
n
```

```
n+
```

```
n+n
```

```
n+ n
```

```
n+  n
```

Задача: у вас есть ЯП довольно мощный. Вы прочитали токен. Вам нужно выдать номер токена. Чтобы делать это быстро нужно Perfect <...> Mapping

Парсеры

Алгоритм Кока-Янгера-Касами

Работает только для грамматик в нормальной форме Хомского ($A \rightarrow BC$). Можно снять ограничение, но это неприятно. Работает за куб от длины слова. Если бы мы парсили за куб ... было бы очень грустно

```
dp_A[l][r] – можно ли получить s[l..r] из A
```

Парсить хочется быстро.

Снизу вверх vs Сверху вниз.

Направление построения дерева. Его можно строить от корня или от листьев (спрашивая какой у них может быть родитель)

Рекурсивный парсер сверху вниз = рекурсивный спуск.

Есть языки, которые так не распарсить.

^ это было введение

Нисходящие методы разбора

```
S → (S)S
```

```
S → ε
```

```
(( ))( )
```

$$S \implies {}^*xA\beta \implies x\eta\beta \implies {}^*xc\beta' \implies {}^*xcz^*$$

Патч: все символы уже подвесили, а первый нераскрытый терминал всё ещё есть. Нужно раскрывать в ε ..

Сейчас определение выше рассматривает бесконечное число выражений (импликаций). Можно сделать, чтобы конечное, об этом позже.